



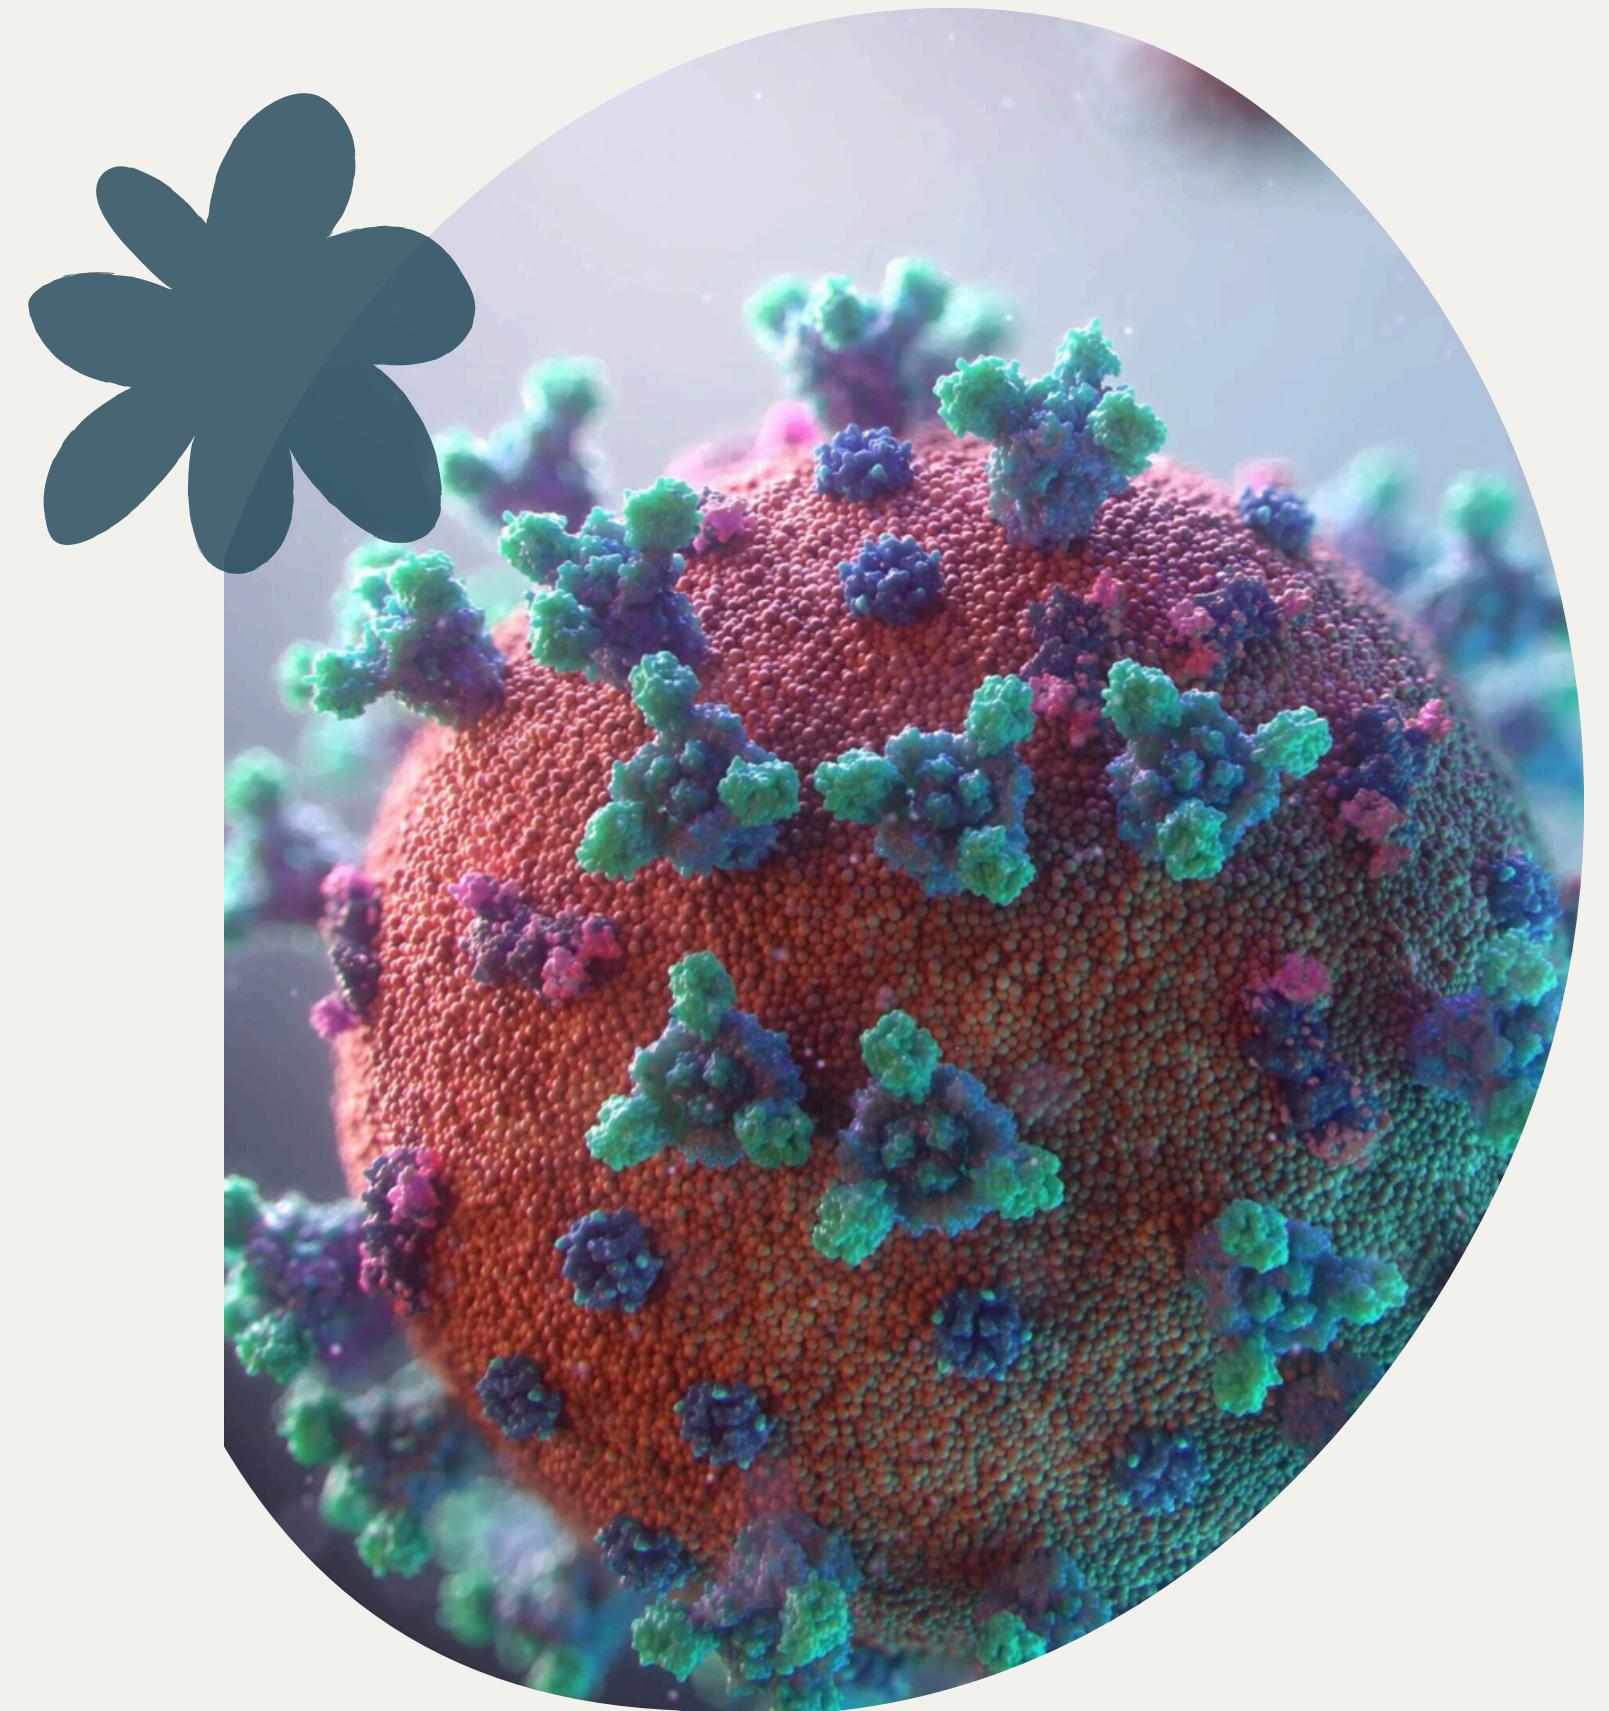
Técnológico de Monterrey

# RETO COVID-19 SEGMENTATION

URI JARED GOPAR MORALES  
JOSÉ ANTONIO MIRANDA BAÑOS  
MARÍA FERNANDA MORENO GÓMEZ

# ÍNDICE

1. Introducción
2. Implicaciones Éticas
3. Análisis de Datos
4. Modelo
5. Entrenamiento
6. Resultados
7. Conclusiones
8. Referencias



# INTRODUCCIÓN

EL 23 DE MARZO DE 2020  
OCURRIÓ UN  
ACONTECIMIENTO QUE  
CAMBIO LA VIDA DE MILLONES  
DE PERSONAS, EL COVID-19.

Para poder identificar a las personas infectadas es necesario realizar una tomografía computarizada (TC), para esto el radiólogo debe de examinar todos los cortes axiales brindados por la computadora para poder identificar las zonas afectadas en los pulmones.



# IMPLICACIONES ÉTICAS



Siempre se deben proteger los datos de los pacientes. La manipulación de imágenes médicas (como las tomografías) implica la gestión de datos sensibles que deben cumplir con normativas estrictas de privacidad, como el Reglamento General de Protección de Datos (GDPR) en Europa, donde resaltan que es crucial garantizar que los datos sean anónimos para que los datos no sean utilizados con otros fines.



Los modelos entrenados con IA no solo deben ser precisos, sino que deben poder ser interpretables, por lo que al trabajar para personas que no son del campo de Tecnologías, debemos de mostrar interpretaciones claras con las que los médicos puedan tomar las mejores decisiones.



Aunque la IA puede ayudar a detectar enfermedades como el COVID, siempre debe estar bajo la supervisión de profesionales médicos. Los resultados obtenidos por los modelos de IA deben ser revisados por especialistas, asegurando que las decisiones finales sean tomadas por médicos, quienes son responsables del diagnóstico y tratamiento del paciente.

# OBJETIVO DE COMPETENCIA

---

Nuestro reto es poder ayudar a los radiólogos a encontrar alguna forma más eficiente de encontrar las zonas más afectadas por el covid-19, mediante la segmentación de imágenes.

La segmentación de imágenes es de gran utilidad para poder detectar las zonas afectadas. Ya que los médicos pueden aislar las zonas con mayor virus, crear planes de mejora personalizados y dar un seguimiento al tratamiento de dicho paciente.



# ANÁLISIS DE DATOS

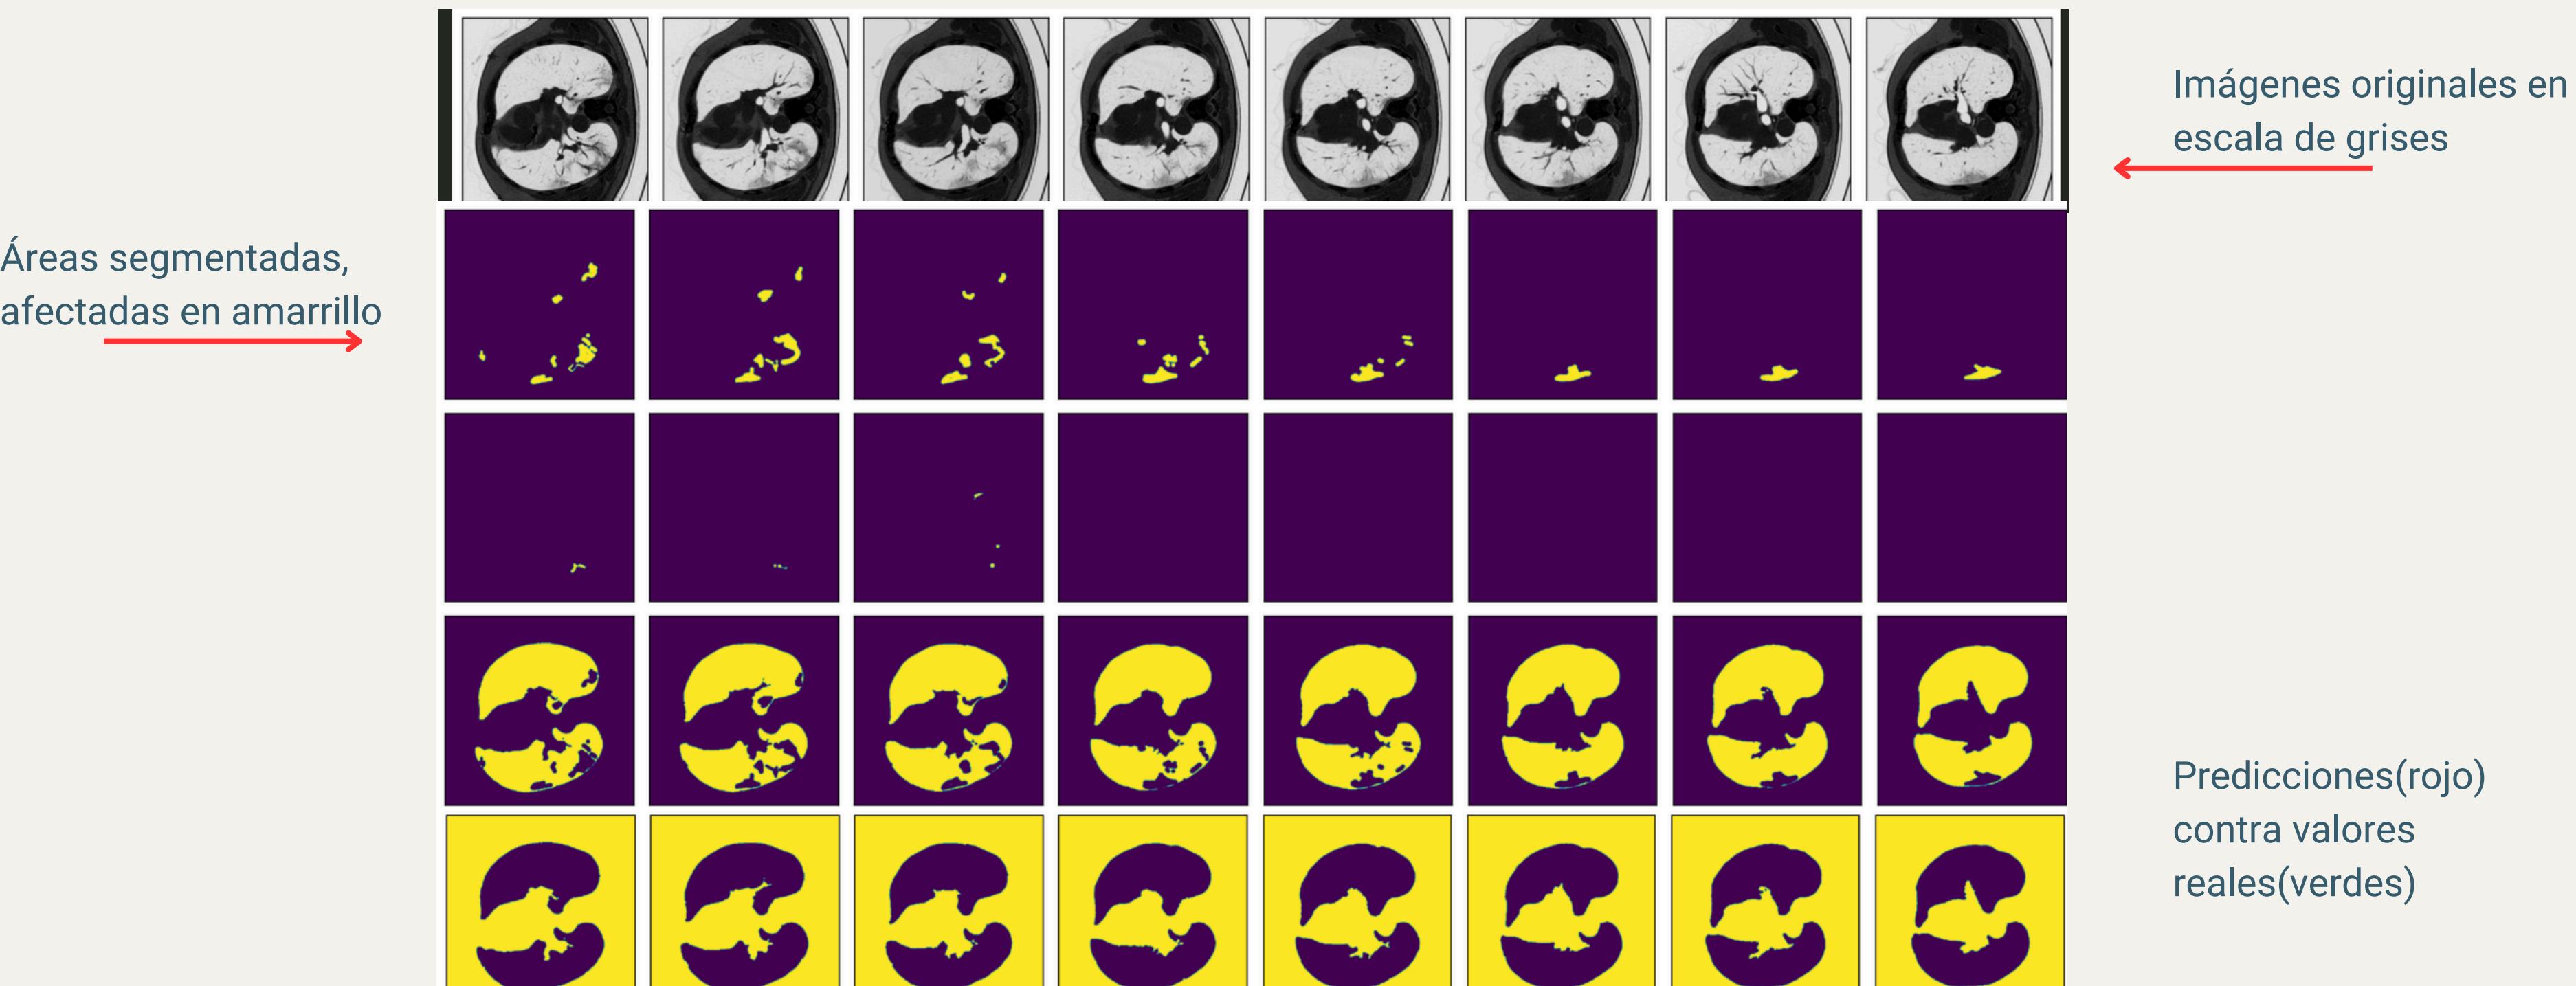
# DATOS:

## Radiografías

El conjunto de datos incluye tomografías computarizadas de pacientes de COVID-19. 829 img

Estas imágenes cuentan con una resolución de 512x512 píxeles.

Tienen máscaras de segmentación marcan las áreas afectadas por el virus en los pulmones.



# PROCESAMIENTO DE LOS DATOS

## Limitamos los píxeles

Los píxeles más altos serán 500 y más bajos -1500 píxeles, esto lo realizamos para evitar valores muy extremos que pueden representar ruido en las imágenes. Facilitamos su comparación.

## Percentiles

Ocupamos los percentiles de 5 y 95 de las imágenes, esto para obtener un rango de los valores que representen mejor el conjunto de datos. Para que los cálculos de la desviación estándar y media

## Media y Desviación Estándar

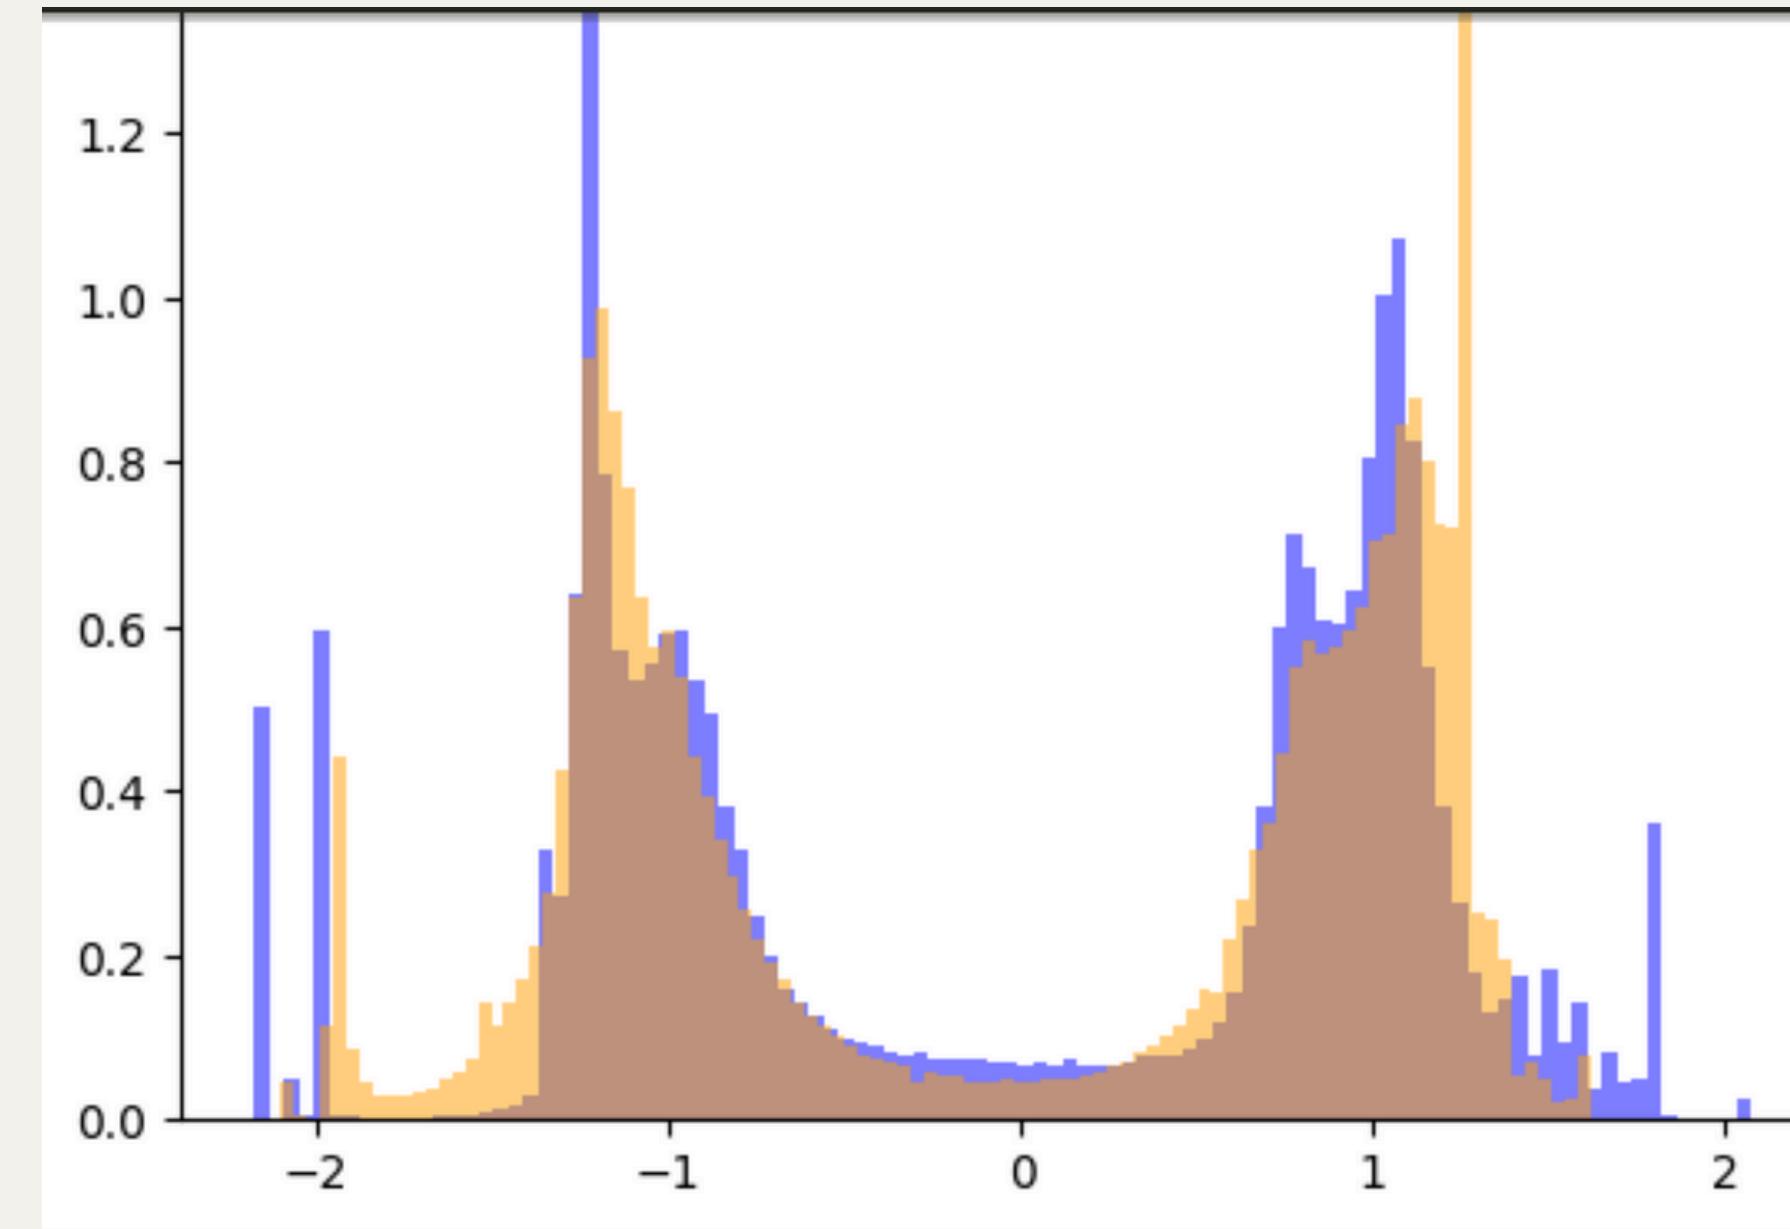
La utilizamos para normalizar las imágenes. Al restar la media y dividir entre la desviación estándar, se escalan dichos valores para tener una media de 0 y desviación estándar de 1. Ayuda al modelo a entrenar

## Imágenes

Al finalizar todo este procesamiento nos quedamos con la imágenes normalizadas , con medias y desviación estandar. Los cuales nos van a servir para normalizar otro conjunto de imágenes y tener consistencia en el procesamiento.

# HISTOGRAMA

En el siguiente histograma vamos a poder observar como es que nuestro método de normalización, permitiendo observar características como el rango de valores, la presencia de valores extremos y la normalización de los datos.



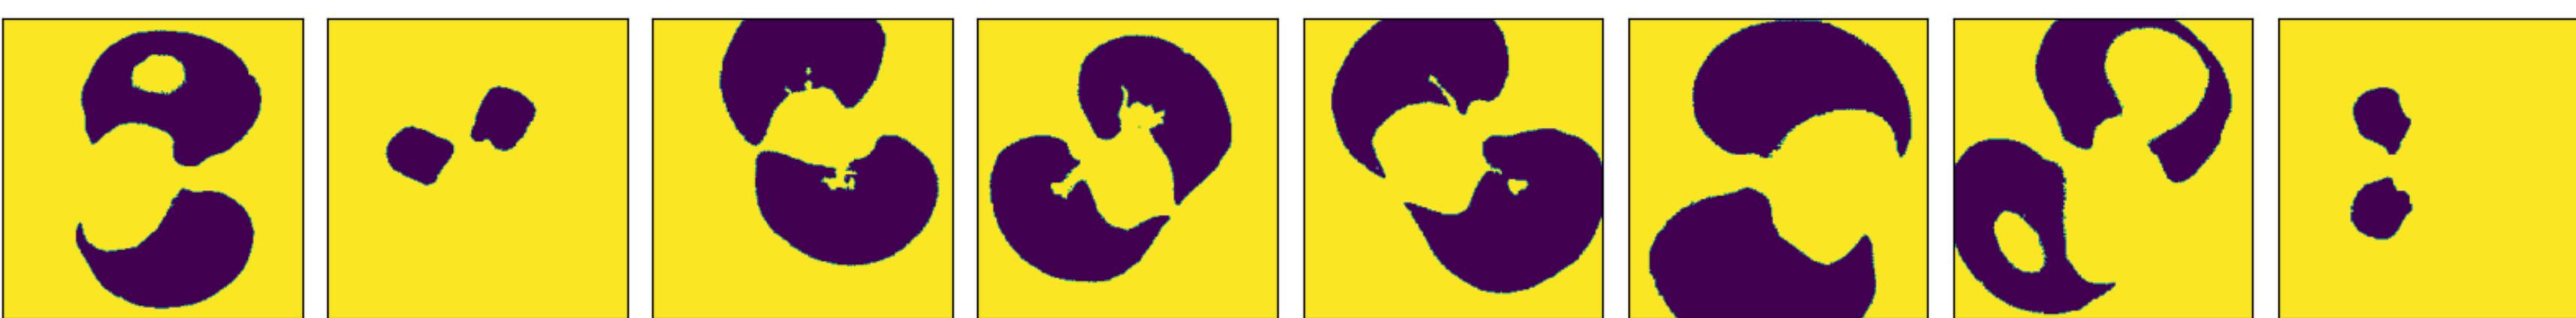
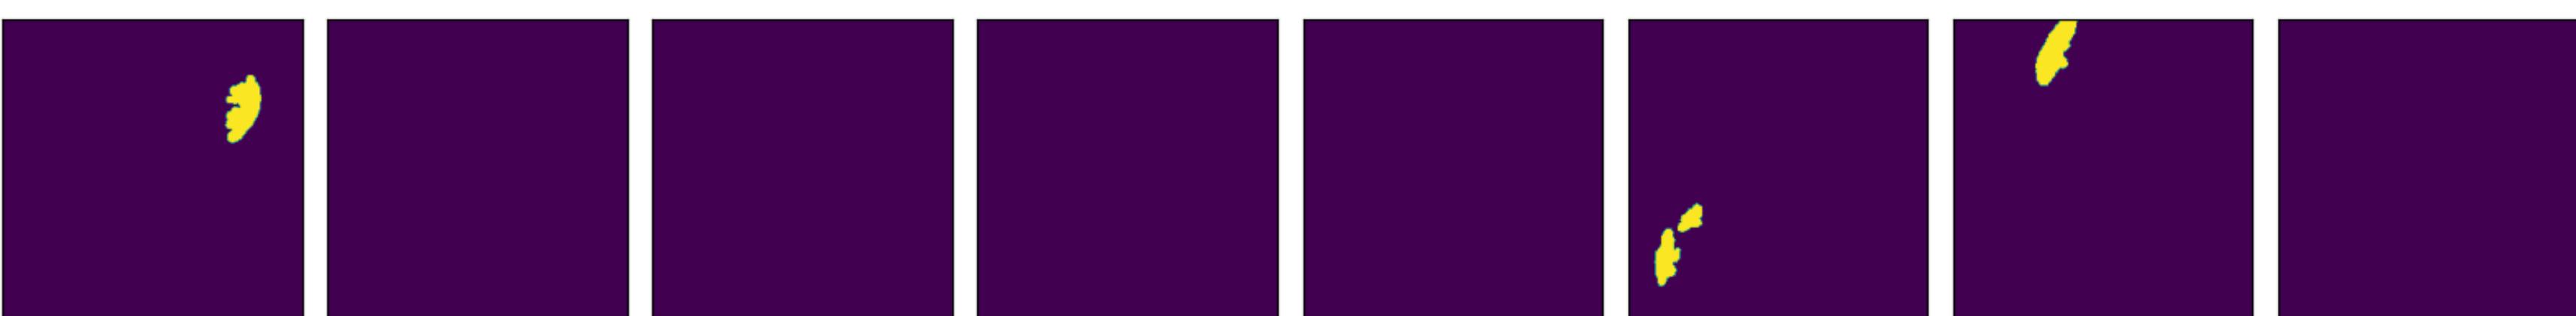
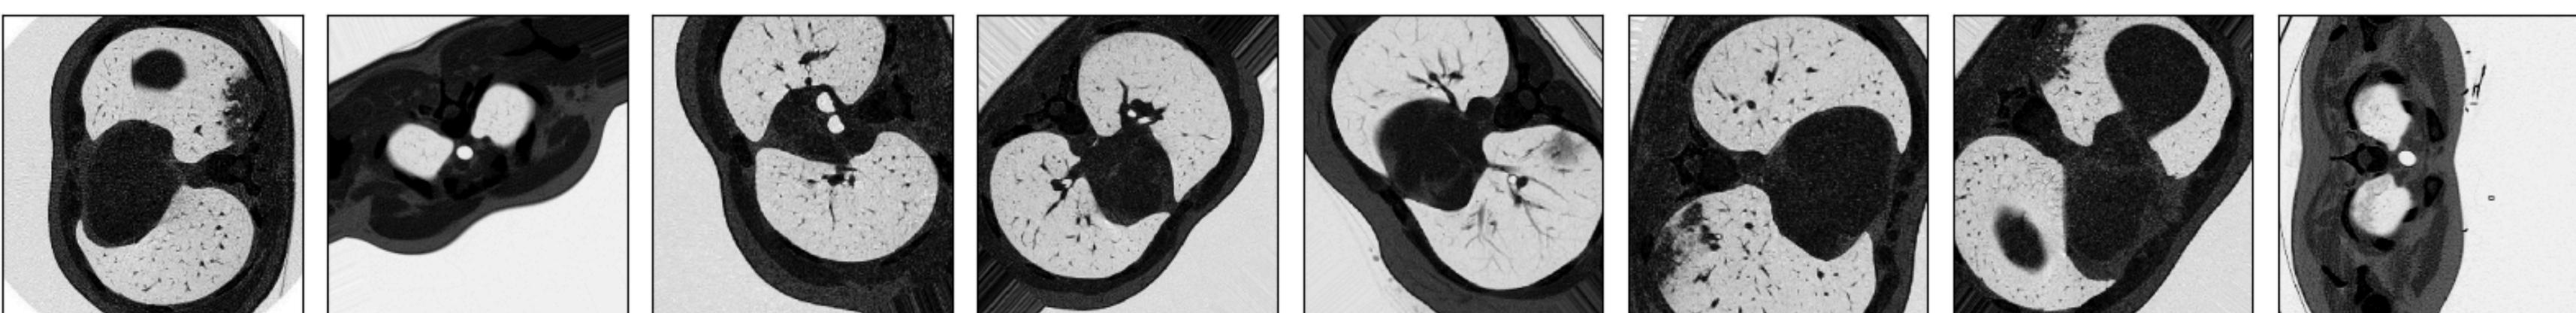
# AUMENTO DE DATOS



\*Ningún perro sufrió de albumentations para esta presentación

Usamos la librería de albumentation para realizar aumento de datos en imágenes, lo que ayuda a mejorar la robustez del modelo.

- Gira las imágenes aleatoriamente hasta 360 grados, replicando los bordes.
- Recorta una parte de la imagen (75-100% del tamaño original) y redimensiona a 256x256 píxeles.
- Invierte horizontalmente algunas imágenes.



# MODELO

# MODELO

Este es un modelo UNet con EfficientNet-B2 como encoder, preentrenado en ImageNet. Toma imágenes en escala de grises (1 canal), segmenta en 4 clases y usa un decoder con 5 salidas. El modelo tiene 5 capas de profundidad en el encoder y no aplica activación final.

Se entrena con un learning rate bajo ( $1e-3$ ) y un weight decay de  $1e-4$  durante 10 epochs, lo que favorece un ajuste gradual y previene el sobreajuste, ideal para segmentación precisa en imágenes como las médicas.

# ENTRENAMIENTO

# PROCESO DE ENTRENAMIENTO

## Preparación de datos

1. Se cargan las imágenes de `images_radiopedia` con sus máscaras
2. Se usa `data augmentation` para aplicar transformaciones en `train`
3. Las imágenes de `validation` se pasan únicamente a una dimensión

## Definición del modelo

1. Modelo de segmentación UNet con un backbone de `efficientnet-b2` preentrenado con los pesos de `imagenet`. Con 4 clases de salidas (clases segmentadas de imágenes).
2. El modelo se construye con una profundidad de codificador de 5, es decir, tiene 5 niveles de comprensión y expansión.

## Configuración de entrenamiento

1. Criterio de pérdida `CrossEntropyLoss` (ideal para problemas de clasificación multi-clase)
2. Se usa el optimizador `AdamW` que agrega un término de regularización de decaimiento de peso.
3. Programador de tasas de aprendizaje `OneCycleLR` que ajusta dinámicamente la tasa de entrenamiento de `train`.

# PROCESO DE ENTRENAMIENTO

## Entrenamiento

En cada epoch, el modelo:

1. Procesa un batch de imágenes.
2. Predice las máscaras correspondientes.
3. Calcula la pérdida usando CrossEntropyLoss.
4. Ajusta los pesos con optimizer.step().
5. Restablece los gradientes con optimizer.zero\_grad().

Después de cada época, el modelo se evalúa en el conjunto de validación, donde no se actualizan los pesos, solo se miden métricas como la precisión por píxel y el IoU para ver si está mejorando.

## Evaluación del rendimiento

1. **Precisión por pixel:** cuántos píxeles de la imagen el modelo predijo correctamente en relación con el total de píxeles.
2. **mIoU:** IoU mide qué tan bien se superponen las áreas predichas con las reales. mIoU es el promedio del IoU para todas las clases de salida.

# PROCESO DE ENTRENAMIENTO

## Guardar el modelo

1. Se guarda el modelo solo cuando mejora el conjunto de validación.
2. Sirve para usar el modelo después si queremos entrenarlo de nuevo.

## Visualización del progreso

Al finalizar el entrenamiento:

1. Se grafica la pérdida, el IoU y la precisión por época (tanto en train como en val)

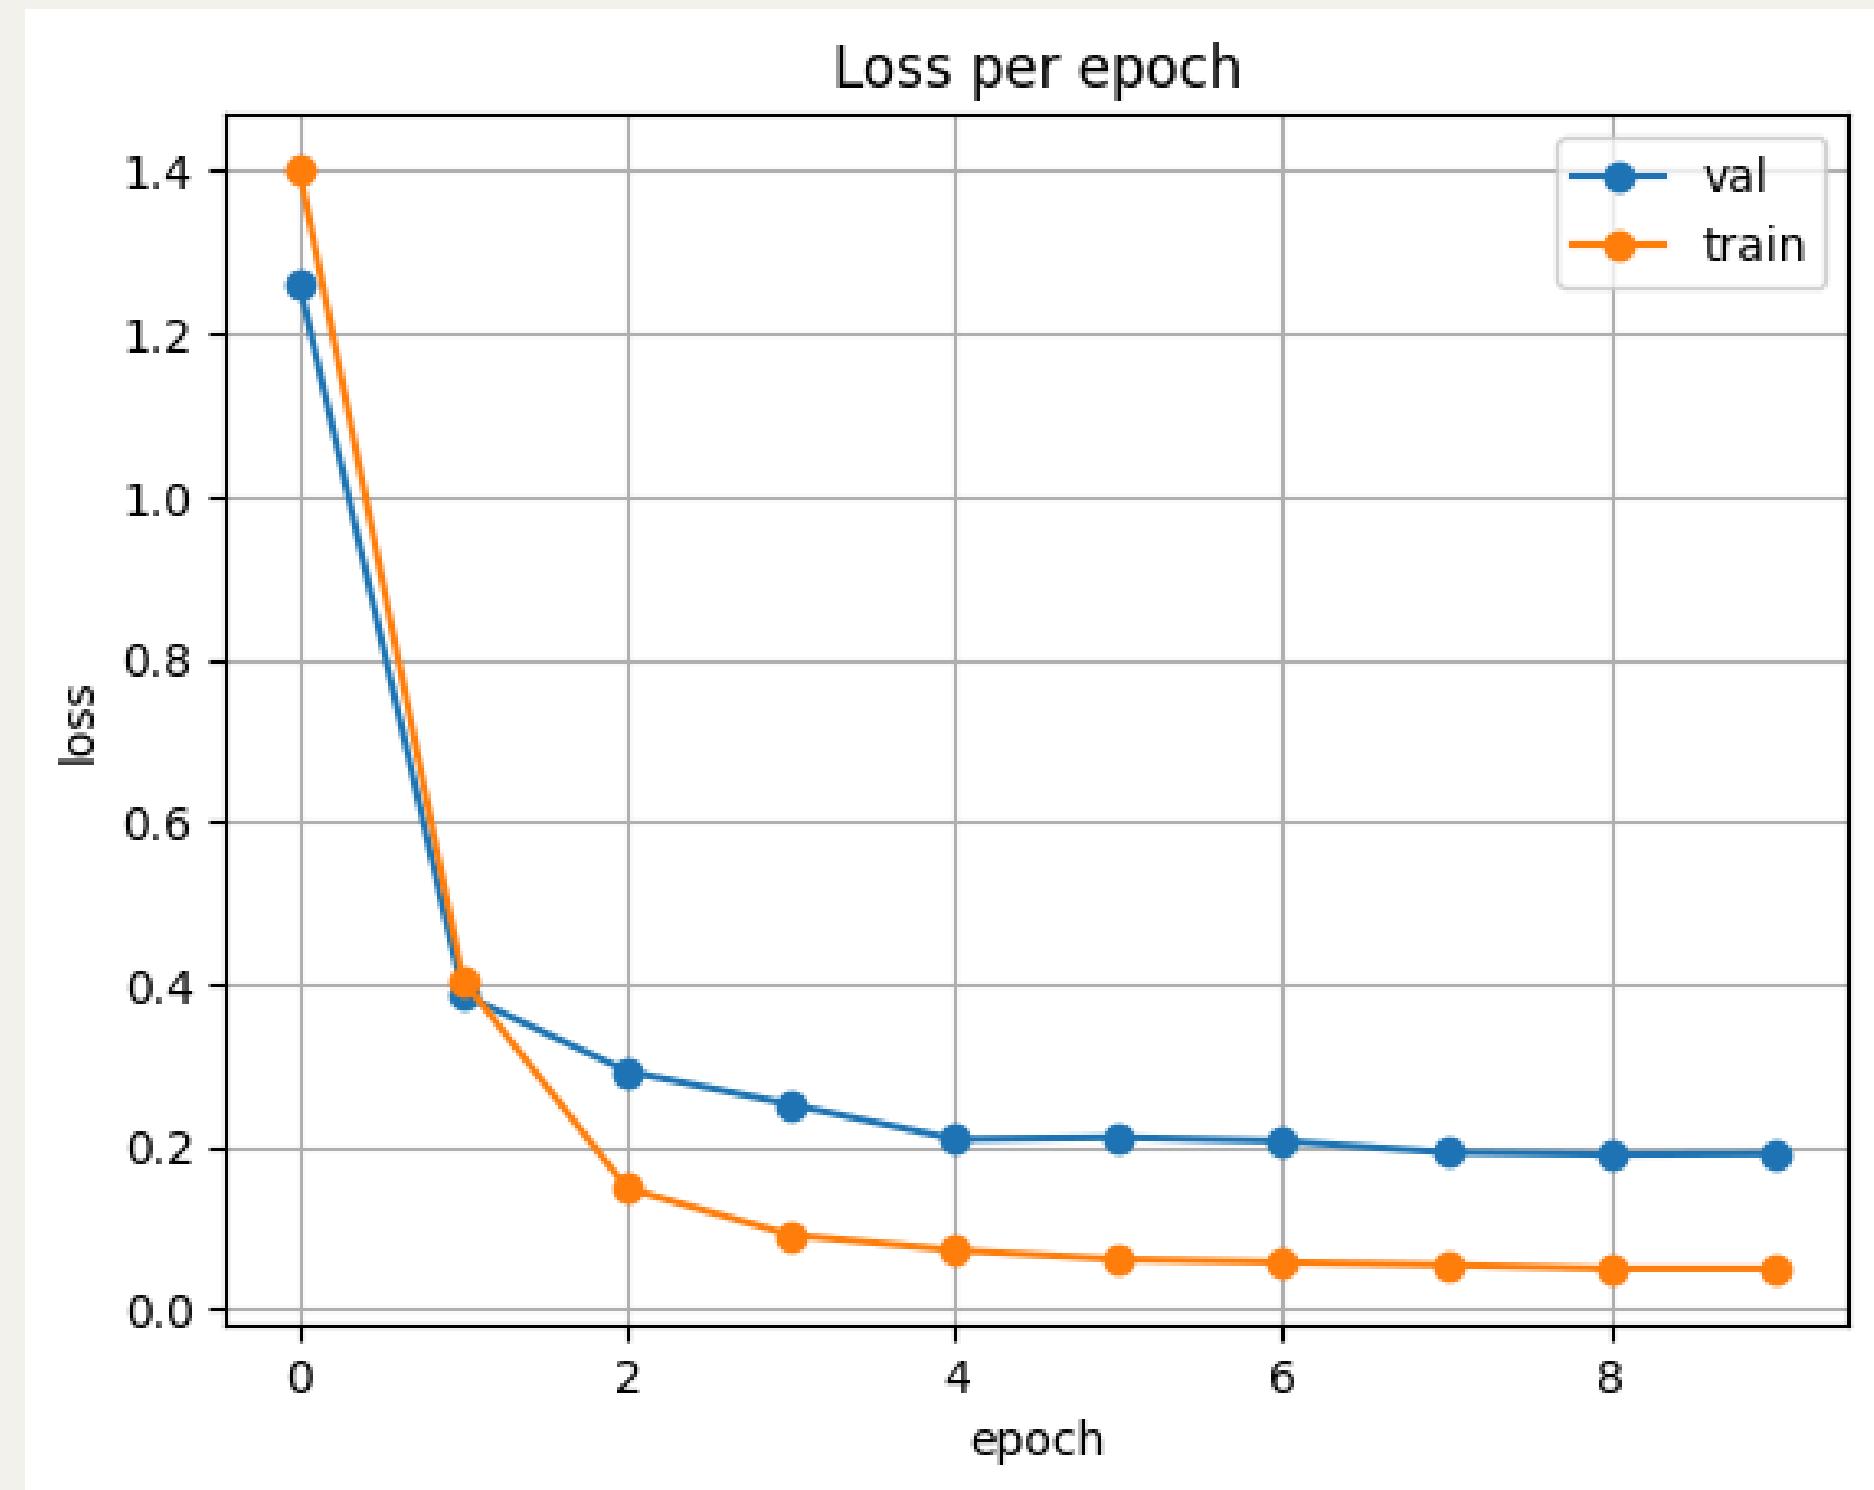
# HARDWARE

Se usó GPU con soporte de CUDA para acelerar el entrenamiento, liberando memoria de la GPU al inicio de cada época.

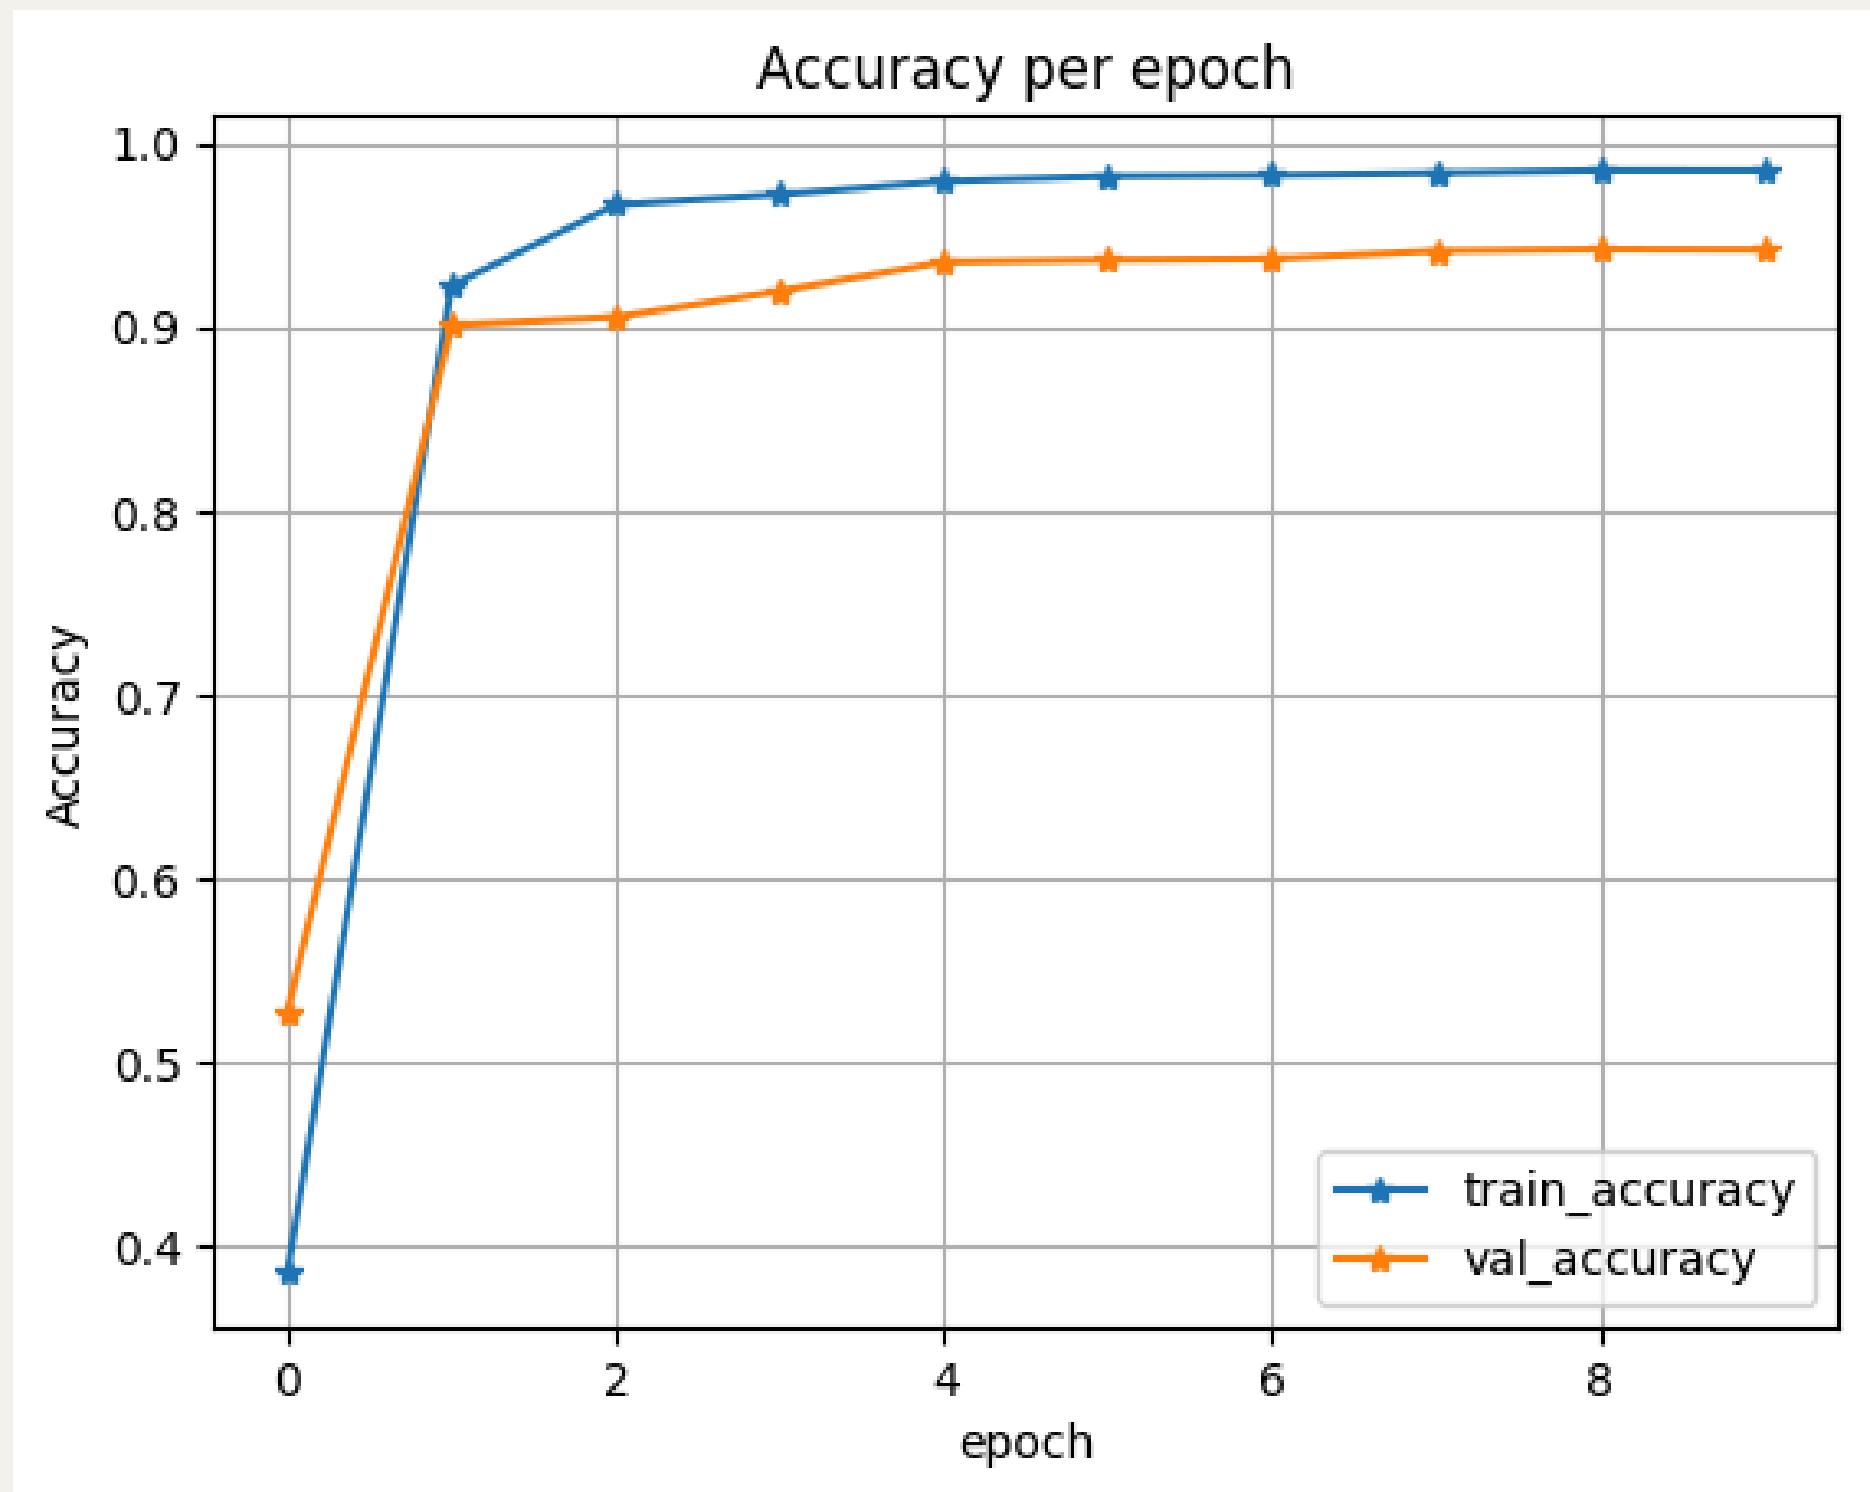


# RESULTADOS

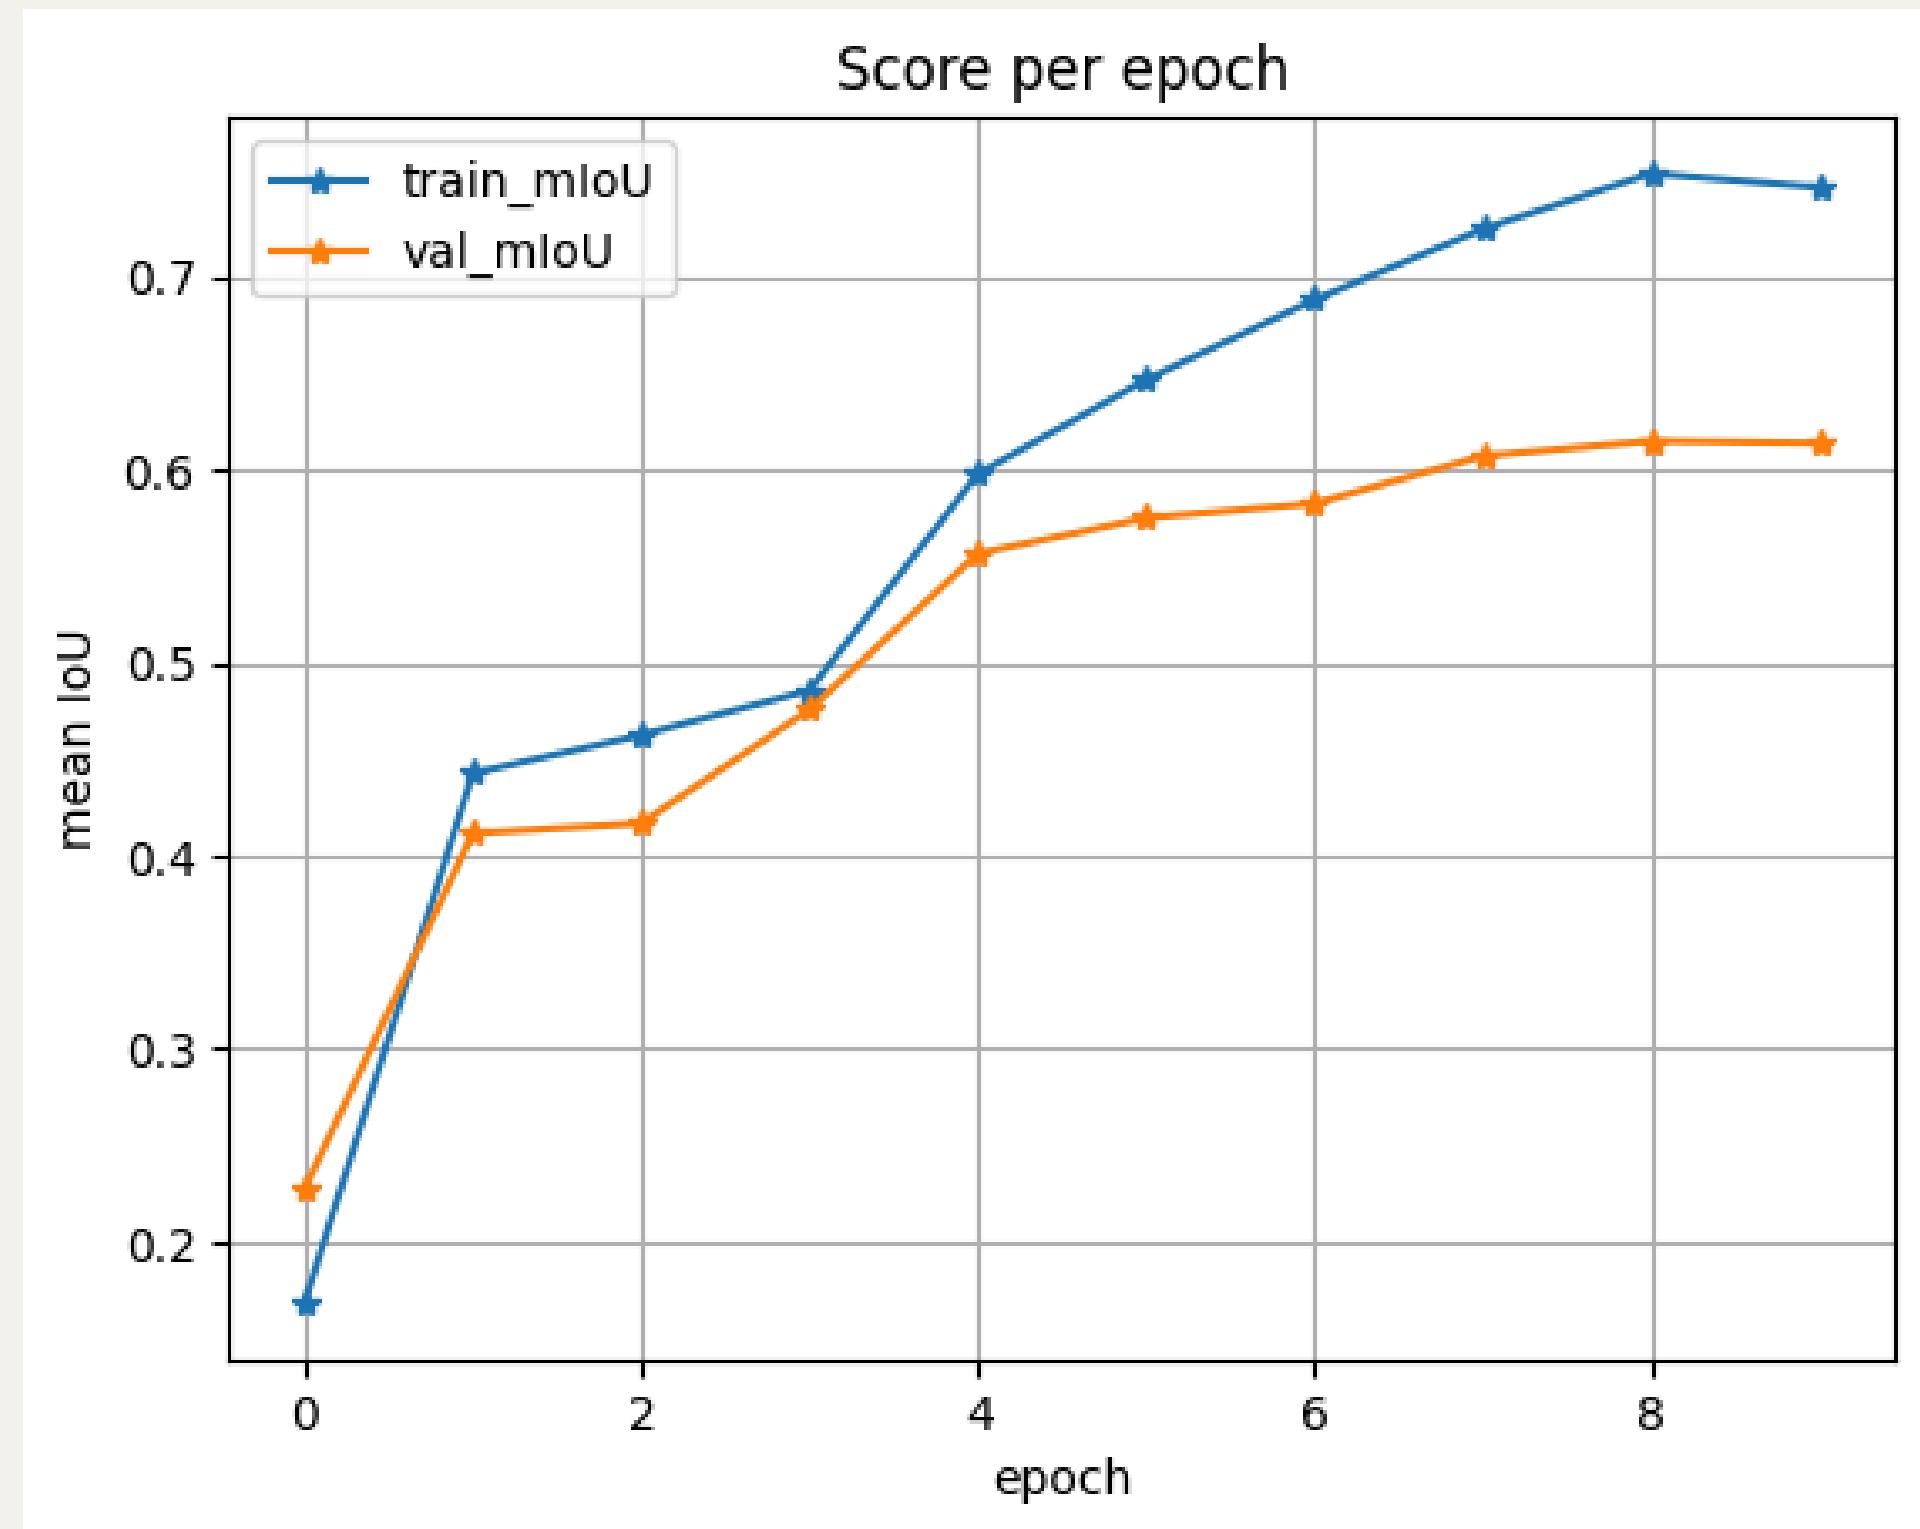
# Loss per Epoch



# Accuracy per Epoch

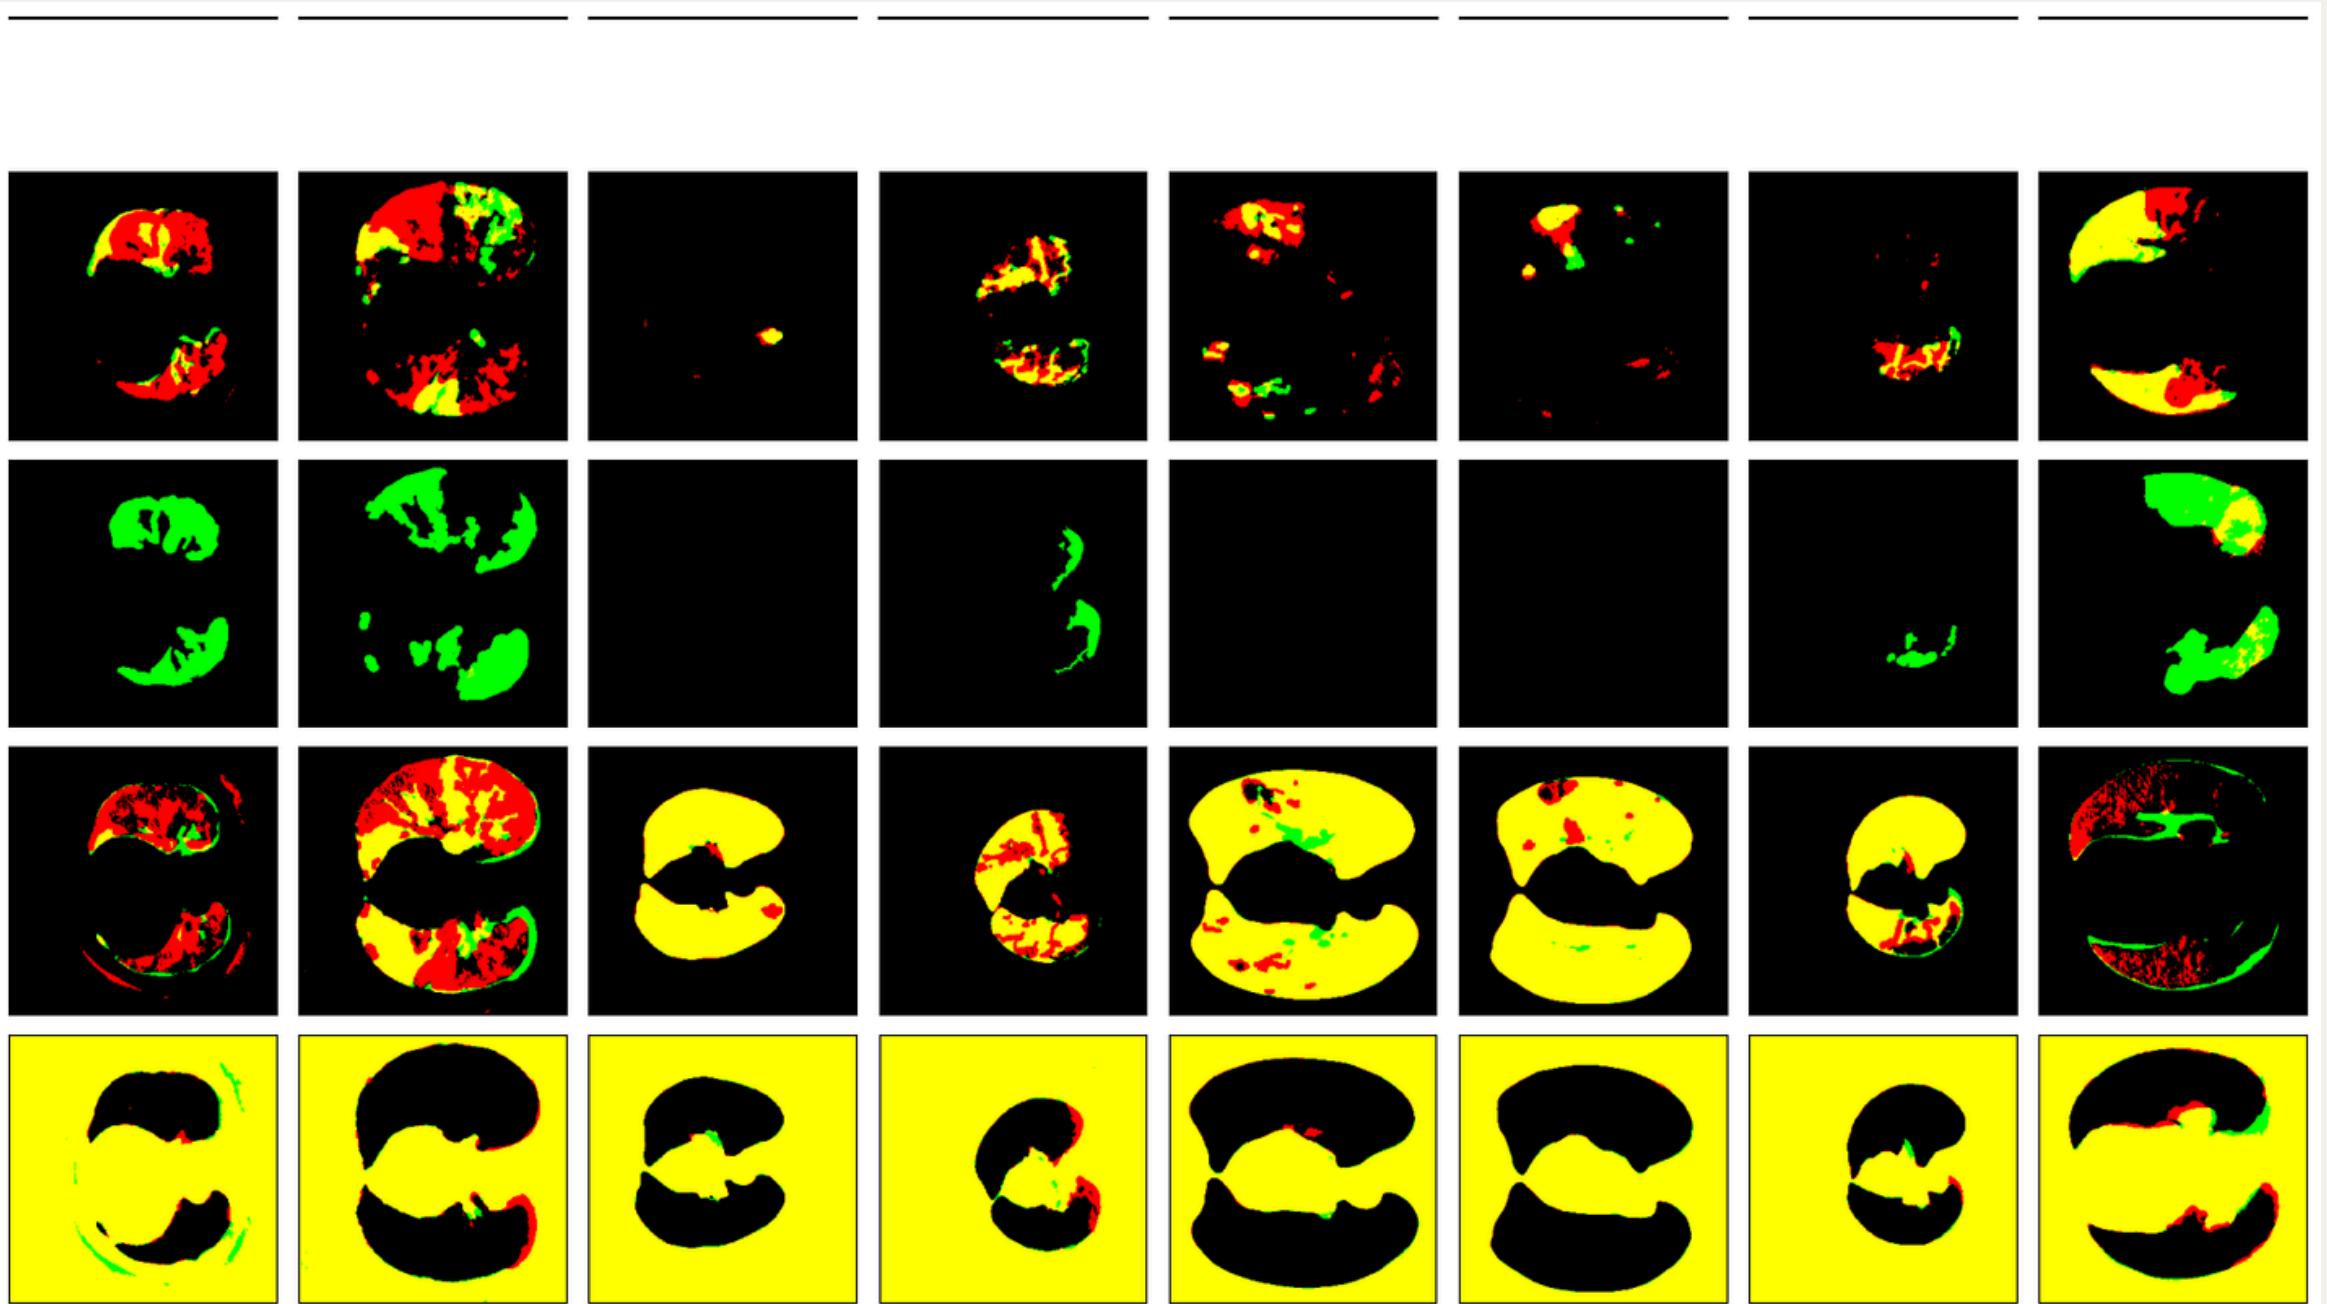


# Score per Epoch



# RESULTADOS

# yellow is TP, red is FP, green is FN



# CONCLUSIONES

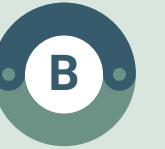
Durante varias pruebas con el modelo nos dimos cuenta que es muy fácil sobrentrenarlo. Esto representa un problema considerando que es un modelo intencionado para su uso en el área medica.

Incluso aumentando los datos nuestro modelo tiene una sobre representación de la tercera mascara, lo cual sesga mucho al modelo. Una sugerencia seria quitar la tercera clase que de hecho no es del todo necesaria.

Esto y conseguir un data set mas grande podría traducirse en un modelo mas completo y con mejor MIoU.

# REFERENCIAS

- Deep Learning Explained with Yacine. (2024, 10 septiembre). Intersection over Union (IoU) Explained with Pytorch [Vídeo]. YouTube.  
[https://www.youtube.com/watch?v=mS\\_csnzZJ-o](https://www.youtube.com/watch?v=mS_csnzZJ-o)
- Lewis, R. (2022, 28 enero). Opacidad del vidrio esmerilado: Causas, síntomas y tratamientos. <https://www.medicalnewstoday.com/articles/es/opacidad-de-vidrio-molido>
- Maedemaftouni. (2021, 8 mayo). PyTorch Baseline for Semantic Segmentation. Kaggle.  
<https://www.kaggle.com/code/maedemaftouni/pytorch-baseline-for-semantic-segmentation/notebook>
- The Radiology Assistant: COVID-19 CO-RADS classification. (s. f.).  
<https://radiologyassistant.nl/chest/covid-19/corads-classification>



Tecnológico de Monterrey

# MUCHAS GRACIAS

Septiembre 2024